

**PREDIKSI PRODUKTIVITAS PADI
MENGUNAKAN MACHINE LEARNING**

Najib Fadhil Akbar

NIM: 301240019

Program Studi Teknik Informatika – Universitas Bale Bandung Mata

Kuliah: Praktikum Kecerdasan Buatan

ABSTRAK

Penelitian ini mengimplementasikan dan membandingkan lima algoritma machine learning untuk memprediksi emisi CO₂ kendaraan bermotor (g/km) menggunakan dataset CO₂ Emission by Vehicles yang bersumber dari Kaggle (Natural Resources Canada) dengan jumlah 7.385 data dan 12 fitur. Algoritma yang diuji meliputi *Linear Regression*, *Decision Tree*, *Random Forest*, *K-Means Clustering*, dan *Backpropagation*. Preprocessing data meliputi Label Encoding untuk variabel kategorik dan StandardScaler untuk normalisasi fitur numerik, dengan pembagian data 70:15:15 (train:validasi:test). Hasil evaluasi menunjukkan Random Forest sebagai model terbaik dengan $R^2 = 0,9973$, MAE = 2,10 g/km, dan RMSE = 2,99 g/km, diikuti Decision Tree ($R^2 = 0,9958$). Linear Regression memberikan baseline yang layak ($R^2 = 0,8810$). K-Means menghasilkan 8 kluster optimal (Inertia = 6.713,80) yang merepresentasikan segmentasi kendaraan berdasarkan profil emisi, sedangkan Backpropagation manual memerlukan tuning lebih lanjut ($R^2 = -6,12$). Seluruh model diintegrasikan dalam aplikasi web berbasis Flask yang berhasil dideploy dengan domain .my.id dan dapat diakses publik.

Kata Kunci: *prediksi emisi CO₂, machine learning, random forest, decision tree, kendaraan bermotor, aplikasi web.*

ABSTRACT

This study implements and compares five machine learning algorithms for predicting CO₂ emissions from motor vehicles (g/km) using the CO₂ Emission by Vehicles dataset sourced from Kaggle (Natural Resources Canada), comprising 7,385 records with 12 features. The algorithms evaluated include *Linear Regression*, *Decision Tree*, *Random Forest*, *K-Means Clustering*, and *Backpropagation*. Data preprocessing includes Label Encoding for categorical variables and StandardScaler for numerical feature normalization, with a 70:15:15 train/validation/test split. Evaluation results show Random Forest as the best model with $R^2 = 0.9973$, MAE = 2.10 g/km, and RMSE = 2.99 g/km, followed by Decision Tree ($R^2 = 0.9958$). Linear Regression provides a reasonable baseline ($R^2 = 0.8810$). K-Means produces 8 optimal clusters (Inertia = 6,713.80) representing vehicle segmentation by emission profile, while manual Backpropagation requires further tuning ($R^2 = -6.12$). All models are integrated into a Flask-based web application successfully deployed with a .my.id domain, accessible to the public.

Keywords: *CO₂ emission prediction, machine learning, random forest, decision tree, vehicle, web application.*

PENDAHULUAN

Sektor transportasi merupakan salah satu kontributor terbesar emisi gas rumah kaca secara global. Menurut International

Energy Agency (IEA, 2022), transportasi darat menyumbang sekitar 16% dari total emisi CO₂ global. Di Indonesia, pertumbuhan jumlah kendaraan bermotor mencapai 5,5% per tahun (BPS, 2023), menjadikan pengelolaan emisi sebagai isu strategis nasional. Kendaraan bermotor konvensional rata-rata

menghasilkan emisi sebesar 200 g CO₂/km, dengan variasi signifikan tergantung pada jenis bahan bakar, kapasitas mesin, dan efisiensi konsumsi.

Kemampuan untuk memprediksi emisi CO₂ secara akurat berdasarkan spesifikasi teknis kendaraan memberikan manfaat multidimensi: regulator dapat merancang kebijakan pembatasan emisi yang berbasis data, produsen otomotif dapat mengoptimalkan desain mesin, dan konsumen dapat membuat keputusan pembelian yang lebih ramah lingkungan. Pendekatan tradisional berbasis pengujian fisik memerlukan biaya dan waktu yang besar, sehingga pendekatan berbasis machine learning (ML) menawarkan alternatif yang lebih efisien dan skalabel.

Penelitian ini mengeksplorasi dan membandingkan lima algoritma machine learning yang representatif: Linear Regression sebagai baseline regresi linier, Decision Tree untuk model berbasis aturan pohon keputusan, Random Forest sebagai metode ensemble yang tangguh, K-Means Clustering untuk analisis segmentasi kendaraan secara unsupervised, dan Backpropagation sebagai implementasi jaringan saraf tiruan secara manual menggunakan NumPy. Kelima model diimplementasikan dalam lingkungan Python 3.9.0 dan selanjutnya diintegrasikan ke dalam aplikasi web berbasis Flask yang dapat diakses publik.

1.1 Rumusan Masalah

- Bagaimana performa komparatif lima algoritma machine learning dalam memprediksi emisi CO₂ kendaraan berdasarkan metrik R², MAE, dan RMSE?
- Algoritma mana yang paling optimal untuk kasus prediksi emisi CO₂ kendaraan?
- Bagaimana klusterisasi K-Means dapat memberikan wawasan segmentasi kendaraan berdasarkan profil emisi?
- Bagaimana mengintegrasikan seluruh model ke dalam aplikasi web interaktif yang dapat diakses publik?

1.2 Tujuan Penelitian

1. Mengimplementasikan lima algoritma machine learning (Linear Regression, Decision Tree, Random Forest, K-Means, Backpropagation) untuk prediksi dan analisis emisi CO₂ kendaraan.
2. Membandingkan performa model secara kuantitatif menggunakan metrik evaluasi standar (R², MAE, RMSE).
3. Menganalisis hasil klusterisasi K-Means untuk menghasilkan segmentasi kendaraan yang bermakna berdasarkan profil emisi.
4. Mengembangkan dan mendeploy aplikasi web prediksi emisi real-time berbasis Flask dengan domain publik.

1.3 Batasan Penelitian

- Dataset yang digunakan adalah CO₂ Emission by Vehicles dari Kaggle (Natural Resources Canada), terbatas pada data kendaraan bermesin bensin dan diesel.
- Implementasi Backpropagation dilakukan secara manual menggunakan NumPy tanpa framework deep learning (TensorFlow/PyTorch).
- Evaluasi performa dilakukan pada dataset statis; pembaruan model secara online (online learning) tidak termasuk dalam scope penelitian.

KAJIAN PUSTAKA

2.1 Penelitian Terdahulu

Beberapa penelitian terdahulu telah mengeksplorasi prediksi emisi CO₂ kendaraan menggunakan pendekatan machine learning. Hidayat Putra (2026) membandingkan Neural Network dan Support Vector Machine (SVM) pada dataset CO₂ kendaraan Kanada, dengan Neural Network unggul dengan F1-score 0,954 berkat kemampuannya dalam menangkap relasi non-linier yang kompleks. Maoelan (2023) mengeksplorasi dataset serupa dengan fokus pada feature selection menggunakan scikit-learn untuk mengidentifikasi fitur-fitur paling prediktif terhadap emisi.

Angela Lisanthoni (2024) membandingkan Random Forest dan XGBoost untuk prediksi emisi karbon secara umum dengan evaluasi menggunakan RMSE, MAE, dan waktu komputasi. Hasil menunjukkan XGBoost sedikit lebih cepat dalam hal waktu komputasi, namun Random Forest lebih konsisten dalam hal generalisasi pada data uji. Penelitian ini

memposisikan kontribusi unik melalui perbandingan yang lebih komprehensif (lima algoritma, termasuk pendekatan unsupervised dan backpropagation manual) serta pengembangan aplikasi web terintegrasi.

2.2 Landasan Teori

2.2.1 Linear Regression

Linear Regression adalah metode statistik klasik yang memodelkan hubungan linier antara variabel independen (fitur) dan variabel dependen (target). Persamaan umum: $\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$, dioptimalkan menggunakan Ordinary Least Squares (OLS) yang meminimalkan jumlah kuadrat residual. Keunggulan utamanya adalah interpretabilitas dan kecepatan komputasi, namun terbatas dalam menangkap hubungan non-linier.

2.2.2 Decision Tree

Decision Tree (Pohon Keputusan) membangun model berbentuk pohon hierarkis di mana setiap simpul internal merepresentasikan sebuah uji pada fitur, setiap cabang merepresentasikan hasil uji, dan setiap daun (leaf) merepresentasikan nilai prediksi. Algoritma CART (Classification and Regression Trees) memilih split pada setiap node yang meminimalkan Mean Squared Error (MSE) untuk kasus regresi. Kelebihan Decision Tree adalah mudah diinterpretasi dan divisualisasikan, namun rentan terhadap overfitting tanpa mekanisme pruning (Géron, 2022).

2.2.3 Random Forest

Random Forest adalah metode ensemble learning yang membangun sejumlah besar Decision Tree secara paralel menggunakan teknik bagging (Bootstrap Aggregating) dan random feature selection. Setiap pohon dilatih pada subset data yang diambil dengan penggantian (bootstrap sample), dan hanya subset fitur secara acak (`max_features='sqrt'`) yang dipertimbangkan pada setiap split. Prediksi akhir diperoleh dengan merata-ratakan output seluruh pohon, menghasilkan model dengan bias rendah dan varians yang terkontrol serta sangat tahan terhadap overfitting (Géron, 2022).

2.2.4 K-Means Clustering

K-Means adalah algoritma klusterisasi unsupervised yang mengelompokkan data ke dalam k kluster berdasarkan jarak

Euclidean ke centroid terdekat. Algoritma bekerja secara iteratif: inisialisasi k centroid secara acak, penugasan setiap data ke centroid terdekat, dan pembaruan centroid sebagai rata-rata semua titik dalam kluster. Proses berulang hingga konvergensi (perubahan centroid di bawah threshold). Pemilihan k optimal dilakukan menggunakan Elbow Method yang memplot nilai inersia (Within-Cluster Sum of Squares) terhadap jumlah kluster.

2.2.5 Backpropagation Neural Network

Backpropagation adalah algoritma pelatihan jaringan saraf tiruan yang menghitung gradien fungsi loss terhadap setiap bobot jaringan menggunakan aturan rantai (chain rule) secara backward dari lapisan output ke lapisan input. Arsitektur jaringan terdiri dari lapisan input, satu atau lebih lapisan tersembunyi (hidden layers) dengan fungsi aktivasi non-linier, dan lapisan output. Optimizer Stochastic Gradient Descent (SGD) memperbarui bobot dengan menggunakan gradien tersebut. Implementasi manual menggunakan NumPy memungkinkan pemahaman mendalam tentang mekanisme internal jaringan (McKinney, 2022; Chollet, 2021).

2.3 Metrik Evaluasi

Tiga metrik utama digunakan untuk mengevaluasi performa model regresi:

R^2 Score (Coefficient of Determination) mengukur proporsi variansi target yang dapat dijelaskan oleh model. Nilai $R^2 = 1$ berarti model sempurna, sedangkan $R^2 = 0$ berarti model tidak lebih baik dari rata-rata. Nilai negatif mengindikasikan model yang lebih buruk dari baseline rata-rata.

Mean Absolute Error (MAE) adalah rata-rata dari nilai absolut perbedaan antara nilai prediksi dan nilai aktual. MAE memiliki satuan yang sama dengan target (g/km) sehingga mudah diinterpretasi secara langsung. MAE lebih robust terhadap outlier dibandingkan MSE.

Root Mean Squared Error (RMSE) adalah akar kuadrat dari rata-rata kuadrat error. RMSE memberikan penalti lebih besar pada error yang besar karena sifat kuadratnya, sehingga lebih sensitif terhadap outlier dibandingkan MAE..

DATASET DAN PREPROCESSING

3.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah CO2 Emission by Vehicles yang dipublikasikan oleh Natural Resources Canada dan tersedia secara publik di platform Kaggle. Dataset ini mencakup data emisi CO₂ aktual dari berbagai model kendaraan yang diuji secara resmi oleh pemerintah Kanada menggunakan prosedur pengujian standar. Dataset memiliki 7.385 baris data dan 12 kolom fitur.

Properti	Nilai	Keterangan
Jumlah Baris	7.385	Data kendaraan unik
Jumlah Kolom	12	Termasuk target
Missing Values	0	Dataset bersih
Target Min	96 g/km	Kendaraan paling efisien
Target Maks	522 g/km	Kendaraan paling boros
Train Set	5.169 data	70% dari total
Validation Set	1.108 data	15% dari total
Test Set	1.108 data	15% dari total
Python Version	3.9.0	Lingkungan eksperimen

Tabel 1. Profil Dataset CO2 Emission by Vehicles

3.2 Deskripsi Fitur

Fitur-fitur yang digunakan dalam pemodelan adalah sebagai berikut:

Tabel 2. Deskripsi Fitur Dataset

Fitur	Tipe Data	Deskripsi	Preprocessing
Engine Size (L)	Numerik	Kapasitas mesin dalam liter	StandardScaler
Cylinders	Numerik	Jumlah silinder mesin	StandardScaler
Fuel Consumption City	Numerik	Konsumsi BBM perkotaan (L/100km)	StandardScaler
Fuel Consumption Hwy	Numerik	Konsumsi BBM jalan raya (L/100km)	StandardScaler
Fuel Consumption Comb	Numerik	Konsumsi BBM kombinasi (L/100km)	StandardScaler

Fuel Type	Kategorik	Jenis bahan bakar (X, Z, D, E, N)	Label Encoding
CO ₂ Emissions (g/km)	Numerik	Target: emisi CO ₂ yang diprediksi	-

3.3 Prosedur Preprocessing

Tahapan preprocessing dilakukan secara sistematis untuk mempersiapkan data sebelum pemodelan:

1. Eksplorasi Data Awal: Pemeriksaan shape (7.385×12), tipe data, distribusi nilai, dan konfirmasi tidak ada missing values.
2. Encoding Variabel Kategorik: Fitur Fuel Type yang bersifat nominal dikodekan menggunakan Label Encoding dari scikit-learn, mengubah kategori string (X, Z, D, E, N) menjadi representasi numerik (0, 1, 2, 3, 4).

METODOLOGI A. Linear Regression

4.1 Kerangka Kerja Penelitian

Penelitian ini mengikuti alur kerja sistematis yang terdiri dari lima tahap utama: (1) Pengumpulan dan eksplorasi data, (2) Preprocessing dan persiapan data, (3) Implementasi dan pelatihan model, (4) Evaluasi dan perbandingan model, dan (5) Integrasi ke aplikasi web dan deployment. Seluruh eksperimen dilakukan menggunakan Python 3.9.0 dengan library scikit-learn 1.x, NumPy, Pandas, Flask, dan Chart.js.

4.2 Implementasi Linear Regression

Model Linear Regression diimplementasikan menggunakan class `LinearRegression()` dari scikit-learn dengan parameter `fit_intercept=True` untuk mengestimasi intercept (β_0). Model dioptimalkan menggunakan metode Ordinary Least Squares (OLS) yang menemukan koefisien regresi yang meminimalkan jumlah kuadrat residual secara analitik. Model ini berfungsi sebagai baseline untuk membandingkan performa algoritma yang lebih kompleks.

4.3 Implementasi Decision Tree

Decision Tree Regressor diimplementasikan menggunakan DecisionTreeRegressor dari scikit-learn dengan konfigurasi: criterion='squared_error' (menggunakan MSE sebagai kriteria pemilihan split) dan max_depth=None (tidak ada pembatasan kedalaman pohon, memungkinkan pohon tumbuh hingga semua leaf murni atau mencapai minimum samples per leaf). Model ini dilatih tanpa pruning untuk mengeksplorasi performa maksimalnya sekaligus menganalisis potensi overfitting.

4.4 Implementasi Random Forest

Random Forest Regressor diimplementasikan menggunakan RandomForestRegressor dari scikit-learn dengan hyperparameter: n_estimators=100 (100 pohon keputusan dalam ensemble), max_features='sqrt' (akar kuadrat dari jumlah total fitur dipertimbangkan pada setiap split), dan random_state=42. Model memanfaatkan paralelisasi internal scikit-learn untuk efisiensi komputasi. Prediksi akhir dihitung sebagai rata-rata aritmetika dari prediksi seluruh 100 pohon.

4.5 Implementasi K-Means Clustering

K-Means Clustering diimplementasikan menggunakan KMeans dari scikit-learn. Penentuan jumlah kluster optimal dilakukan menggunakan Elbow Method: model dilatih untuk $k = 1$ hingga 15, dan nilai inersia (Within-Cluster Sum of Squares) diplot terhadap k . Titik 'siku' (elbow) pada grafik mengindikasikan k optimal. Hasil analisis menunjukkan $k=8$ sebagai jumlah kluster terbaik dengan parameter $n_clusters=8$ dan $n_init=10$. Berbeda dengan model supervised, K-Means beroperasi tanpa label target, mengelompokkan kendaraan berdasarkan kemiripan profil fitur emisi dan konsumsi bahan bakar.

4.6 Implementasi Backpropagation (Manual NumPy)

Backpropagation diimplementasikan secara eksplisit menggunakan NumPy tanpa framework deep learning. Arsitektur jaringan terdiri dari lapisan input (jumlah neuron = jumlah fitur), dua hidden layer (64 dan 32 neuron), dan lapisan output (1 neuron untuk prediksi regresi). Fungsi aktivasi ReLU (Rectified Linear Unit) digunakan pada hidden layers, dan inisialisasi bobot menggunakan metode He (He Initialization) yang cocok untuk ReLU. Optimizer yang digunakan adalah Stochastic Gradient Descent (SGD) standar dengan learning rate 0,01. Model dilatih selama 100 epoch.

HASIL DAN PEMBAHASAN A. Perbandingan Performa Model Supervised

B

Tabel 3. Ringkasan Hyperparameter Seluruh Model

Model	Parameter	Nilai	Justifikasi
Linear Regression	fit_intercept	True	Estimasi intercept
Decision Tree	criterion	squared_error	Regresi berbasis MSE
Decision Tree	max_depth	None (auto)	Tidak ada pruning
Random Forest	n_estimators	100	Ensemble cukup besar
Random Forest	max_features	sqrt	Standar RF regresi
Random Forest	random_state	42	Reproduktibilitas
K-Means	n_clusters	8	Elbow Method
K-Means	n_init	10	Stabilitas centroid
Backpropagation	hidden_layers	64 → 32	Arsitektur bertingkat
Backpropagation	learning_rate	0,01	SGD standar
Backpropagation	epochs	100	Iterasi pelatihan
Backpropagation	activation	ReLU	Non-linearitas

5.1 Perbandingan Performa Model Supervised

Evaluasi performa seluruh model supervised dilakukan pada test set (1.108 data) yang tidak pernah dilihat selama proses pelatihan maupun validasi. Tabel 4 merangkum hasil evaluasi kuantitatif berdasarkan tiga metrik utama:

Tabel 4. Perbandingan Metrik Evaluasi Model (Test Set, Python 3.9.0)

Algoritma	MAE (g/km)	RMSE (g/km)	R ² Score	Peringkat
Linear Regression	13,46	20,03	0,8810	4
Decision Tree	2,22	3,75	0,9958	2

Random Forest ★	2,10	2,99	0,9973	1
K-Means (k=8)	—	Inertia: 6.713, 80	—	Unsupervised
Backpropagation*	112,0 9	154,96	-6,12 43	5*

*Backpropagation manual (NumPy) menunjukkan R^2 negatif akibat optimizer SGD standar yang belum dioptimalkan. Diperlukan perbaikan: adaptive learning rate (Adam/RMSProp), normalisasi output, dan penambahan batch normalization.

5.2 Analisis Detail Model Terbaik: Random Forest

Random Forest mencapai performa terbaik dengan $R^2 = 0,9973$, yang berarti model mampu menjelaskan 99,73% variansi emisi CO₂ pada data uji. Dengan MAE = 2,10 g/km, rata-rata kesalahan prediksi sangat kecil dibandingkan rentang emisi data (96–522 g/km, range = 426 g/km), yang berarti error rata-rata hanya sebesar 0,49% dari rentang nilai target.

Superioritas Random Forest dapat dijelaskan oleh beberapa faktor: (1) Ensemble averaging dari 100 pohon secara efektif mengurangi varians tanpa meningkatkan bias secara signifikan; (2) Random feature selection pada setiap split mencegah korelasi berlebihan antar pohon; (3) Kemampuan menangkap interaksi non-linier antar fitur yang tidak dapat dimodelkan oleh Linear Regression; (4) Robustness terhadap outlier yang mungkin ada dalam data emisi kendaraan ekstrem (supercar/heavy truck).

5.3 Analisis Decision Tree

Decision Tree menunjukkan performa yang hampir menyamai Random Forest dengan $R^2 = 0,9958$, MAE = 2,22 g/km, dan RMSE = 3,75 g/km. Performa tinggi ini dimungkinkan karena data emisi CO₂ kendaraan memiliki pola yang relatif terstruktur dan dapat ditangkap oleh aturan-aturan pohon keputusan.

Namun, tanpa pruning (max_depth=None), pohon keputusan berpotensi mengalami overfitting pada data training dengan memorisasi noise. Perbandingan antara performa validation

set dan test set perlu dianalisis lebih lanjut untuk mengonfirmasi hal ini. Untuk deployment produksi, penggunaan cross-validation dan hyperparameter tuning pada max_depth dan min_samples_split sangat direkomendasikan.

5.4 Analisis Linear Regression

Linear Regression sebagai model baseline memberikan performa yang masih layak dengan $R^2 = 0,8810$, mengindikasikan bahwa sekitar 88,10% variansi emisi CO₂ dapat dijelaskan oleh hubungan linier dengan fitur-fitur input. Hal ini mengkonfirmasi adanya hubungan dominan yang linier antara konsumsi bahan bakar (terutama Fuel Consumption Comb) dan emisi CO₂, yang memang secara fisik logis.

Namun, sisa 11,90% variansi yang tidak dapat dijelaskan menunjukkan bahwa terdapat komponen non-linier yang signifikan, seperti pengaruh interaksi antara jenis bahan bakar dan kapasitas mesin. MAE = 13,46 g/km berarti rata-rata kesalahan prediksi sekitar 6,7% dari rentang emisi, yang mungkin masih dapat diterima untuk aplikasi estimasi kasar namun tidak cukup presisi untuk keperluan regulasi.

5.5 Analisis K-Means Clustering (k=8)

K-Means berhasil membentuk 8 kluster yang bermakna secara semantik berdasarkan profil emisi dan konsumsi bahan bakar kendaraan. Nilai inertia = 6.713,80 pada k=8 menunjukkan kohesi kluster yang baik (semakin kecil inertia, semakin kompak kluster). Interpretasi setiap kluster berdasarkan analisis centroid:

Tabel 5. Interpretasi 8 Kluster K-Means (Inertia = 6.713,80)

Kluster	Kategori	Rentang CO ₂	Tipe Kendaraan Representatif
1	Emisi Sangat Rendah	< 130 g/km	Kendaraan listrik/hybrid, city car
2	Emisi Rendah	130–180 g/km	Compact car, sedan efisien
3	Emisi Rendah-Sedang	180–220 g/km	Sedan standar, hatchback
4	Emisi Sedang	220–260 g/km	SUV kecil, crossover

5	Emisi Sedang-Tinggi	260–300 g/km	SUV menengah, minivan
6	Emisi Tinggi	300–360 g/km	Pickup truck, van komersial
7	Emisi Sangat Tinggi	360–420 g/km	Truk besar, muscle car
8	Emisi Ekstrem	> 420 g/km	Supercar, heavy truck

Segmentasi ini memberikan nilai praktis bagi regulator (untuk menetapkan kelas pajak emisi), produsen (untuk memposisikan produk dalam segmen pasar), dan konsumen (untuk membandingkan efisiensi lingkungan antar kendaraan).

5.6 Analisis Backpropagation

Implementasi Backpropagation manual menggunakan NumPy menunjukkan $R^2 = -6,12$, MAE = 112,09 g/km, dan RMSE = 154,96 g/km, yang mengindikasikan model gagal berkonvergensi dengan baik menggunakan konfigurasi saat ini. Meski demikian, catatan loss per epoch menunjukkan tren penurunan yang benar:

Tabel 6. Progres Training Loss Backpropagation (100 Epoch)

Epoch	Training Loss	Penurunan Loss	Keterangan
0	2,928639	—	Inisialisasi awal
20	0,342953	-88,3%	Penurunan signifikan awal
40	0,221105	-35,5%	Konvergensi melambat
60	0,174948	-20,9%	Plateauing
80	0,144444	-17,4%	Konvergensi lambat
100	~0,130*	-10,0%*	Perlu lebih banyak epoch

*Estimasi berdasarkan tren penurunan. Perbaikan yang direkomendasikan: (1) Penggunaan adaptive optimizer seperti Adam atau RMSProp; (2) Normalisasi nilai target output (output normalization) menggunakan MinMaxScaler agar berada dalam rentang yang sesuai dengan fungsi aktivasi; (3) Penambahan batch normalization pada hidden layers; (4)

Peningkatan jumlah epoch menjadi minimal 500–1000; (5) Implementasi early stopping untuk mencegah overfitting.

IMPLEMENTASI APLIKASI WEB

6.1 Arsitektur Sistem

Aplikasi web dibangun menggunakan arsitektur Model-View-Controller (MVC) dengan stack teknologi berikut:

Tabel 7. Stack Teknologi Aplikasi Web

Layer	Teknologi	Fungsi
Backend	Python 3.9.0 + Flask	REST API, logika prediksi, serving model
Frontend	Bootstrap 5 + Chart.js	Antarmuka responsif + visualisasi interaktif
WSGI Server	Gunicorn	Production-grade server untuk Flask
Model Storage	joblib (.pkl)	Serialisasi model scikit-learn
NN Weights	NumPy (.npy)	Penyimpanan bobot Backpropagation
Deployment	Railway.app	Cloud platform hosting
CDN/Proxy	Cloudflare	DNS management + proteksi DDoS
Domain	.my.id	Domain publik Indonesia

6.2 Fitur-fitur Aplikasi

Aplikasi web yang dikembangkan mencakup empat fitur utama:

1. Form Prediksi Emisi Real-time: Pengguna dapat memasukkan spesifikasi kendaraan (ukuran mesin, jumlah silinder, konsumsi BBM kota/highway/kombinasi, jenis bahan bakar) dan mendapatkan prediksi emisi CO₂ dari kelima model secara simultan, memungkinkan perbandingan langsung antar model.
2. Dashboard Perbandingan Model: Halaman interaktif yang menampilkan perbandingan metrik evaluasi (MAE, RMSE, R²) seluruh model dalam bentuk bar chart interaktif menggunakan Chart.js, berdasarkan data aktual dari eksperimen Python.
3. Visualisasi Kluster K-Means: Scatter plot interaktif yang menampilkan distribusi data kendaraan dalam

ruang 2D (menggunakan PCA untuk reduksi dimensi) dengan warna berbeda untuk setiap kluster, disertai interpretasi semantik setiap kluster.

4. Antarmuka Responsif: Desain responsif berbasis Bootstrap 5 yang dapat diakses dengan nyaman melalui perangkat mobile maupun desktop.

6.3 Endpoint API

Aplikasi Flask menyediakan beberapa endpoint API:

Tabel 8. Endpoint REST API Aplikasi Web

Method	Endpoint	Fungsi	Parameter Input
GET	/	Halaman utama (form prediksi)	—
POST	/predict	Prediksi dari semua model	JSON: spesifikasi kendaraan
GET	/compare	Dashboard perbandingan model	—
GET	/cluster	Visualisasi K-Means	—
GET	/api/metrics	Metrik evaluasi dalam JSON	—

6.4 Deployment

Proses deployment dilakukan melalui pipeline: Railway.app (hosting cloud) → Cloudflare (DNS management dan proteksi) → Domain .my.id. Railway.app dipilih karena mendukung deployment langsung dari GitHub repository dengan konfigurasi Procfile untuk Gunicorn. Model yang telah dilatih disimpan sebagai file .pkl (model scikit-learn) dan .npz (bobot NumPy untuk Backpropagation) dan di-load saat startup aplikasi untuk meminimalkan latency prediksi.

Repository GitHub: <https://github.com/Atsaalnajwan7/WEB-Prediksi-emisi-CO2-Kendaraan-UTS-AI.git>

URL Deployment: <https://web-prediksi-emisi-co2-kendaraan-uts-ai-production.up.railway.app/>

Demonstrasi Video: <https://youtu.be/MBdTIJWREF4>

KESIMPULAN

7.1 Kesimpulan

Berdasarkan hasil eksperimen pada dataset 7.385 data kendaraan menggunakan Python 3.9.0, penelitian ini menghasilkan kesimpulan sebagai berikut:

1. Random Forest terbukti sebagai model terbaik untuk prediksi emisi CO₂ kendaraan dengan $R^2 = 0,9973$, MAE = 2,10 g/km, dan RMSE = 2,99 g/km. Performa unggul ini disebabkan oleh mekanisme ensemble averaging yang secara efektif mengurangi varians tanpa meningkatkan bias secara signifikan, serta kemampuan menangkap hubungan non-linier dalam data.
2. Decision Tree memberikan performa kompetitif ($R^2 = 0,9958$) namun berpotensi overfit tanpa mekanisme pruning. Untuk aplikasi produksi, diperlukan hyperparameter tuning yang lebih cermat.
3. Linear Regression sebagai baseline tetap memberikan performa yang layak ($R^2 = 0,8810$), mengkonfirmasi adanya hubungan dominan linier antara konsumsi bahan bakar dan emisi CO₂. Model ini berguna untuk estimasi cepat dengan interpretabilitas tinggi.
4. K-Means Clustering berhasil membentuk 8 kluster bermakna (Inertia = 6.713,80) yang memberikan wawasan segmentasi kendaraan berdasarkan profil emisi, berguna untuk analisis pasar dan perumusan kebijakan emisi berbasis data.
5. Backpropagation manual memerlukan optimasi lanjutan (adaptive learning rate, output normalization, batch normalization) untuk mencapai konvergensi yang stabil dan performa yang kompetitif dengan model lainnya.
6. Aplikasi web berbasis Flask berhasil mengintegrasikan seluruh model dan dapat diakses publik melalui domain .my.id, membuktikan feasibilitas deployment model machine learning untuk prediksi emisi real-time.

7.2 Saran dan Arah Penelitian Mendatang

1. Implementasikan Backpropagation menggunakan framework modern (TensorFlow/PyTorch) dengan

- optimizer Adam, batch normalization, dan dropout untuk perbandingan yang lebih adil dengan model deep learning.
2. Eksplorasi algoritma ensemble lainnya seperti XGBoost, LightGBM, atau CatBoost yang seringkali mengungguli Random Forest pada dataset tabular.
 3. Terapkan teknik interpretabilitas model (SHAP values, LIME, Permutation Feature Importance) untuk memahami kontribusi setiap fitur terhadap prediksi emisi.
 4. Kembangkan sistem prediksi yang mendukung pembaruan model secara online (online learning) untuk mengakomodasi data kendaraan terbaru.
 5. Perluas dataset dengan mengintegrasikan data kendaraan Indonesia dari Kementerian ESDM atau KLHK untuk model yang lebih relevan dengan konteks lokal.
 6. Implementasikan API terbuka (open API) agar model prediksi dapat diintegrasikan ke dalam sistem informasi pihak ketiga seperti aplikasi otomotif atau platform perdagangan kendaraan.
-
- #### DAFTAR PUSTAKA
- [1] Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly Media.
 - [2] McKinney, W. (2022). Python for Data Analysis (3rd ed.). O'Reilly Media.
 - [3] Hidayat Putra. (2026). Pemodelan Prediktif Emisi CO₂ Kendaraan Kanada: Neural Network vs SVM. International Journal of Artificial Intelligence (IJAI).
 - [4] Angela Lisanthoni. (2024). Prediksi Emisi Karbon: Random Forest vs XGBoost. GitHub Repository. Tersedia di: <https://github.com>
 - [5] Maoelan. (2023). Feature Selection dan Prediksi Emisi CO₂ Kendaraan Menggunakan scikit-learn. Jurnal Ilmu Komputer Indonesia.
 - [6] Scikit-learn Developers. (2024). scikit-learn: Machine Learning in Python (Dokumentasi Resmi). Tersedia di: <https://scikit-learn.org>
 - [7] Grinberg, M. (2018). Flask Web Development: Developing Web Applications with Python (2nd ed.). O'Reilly Media.
 - [8] International Energy Agency (IEA). (2022). CO₂ Emissions from Fuel Combustion 2022. IEA Publications. Tersedia di: <https://www.iea.org>
 - [9] Badan Pusat Statistik (BPS). (2023). Statistik Transportasi Indonesia 2023. BPS-Statistics Indonesia. Tersedia di: <https://bps.go.id>
 - [10] Natural Resources Canada. (2022). CO₂ Emission by Vehicles Dataset. Kaggle. Tersedia di: <https://www.kaggle.com/datasets/debajyotipodder/co2-emission-by-vehicles>
 - [11] Chollet, F. (2021). Deep Learning with Python (2nd ed.). Manning Publications.
 - [12] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32. Springer.
 - [13] MacQueen, J. (1967). Some Methods for Classification and Analysis of Multivariate Observations. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1(14), 281–297.
 - [14] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning Representations by Back-propagating Errors. Nature, 323(6088), 533–536.
 - [15] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Lampiran A: Tautan Sumber Daya Proyek

Youtube :

Github:

Domain:

			6.713,80		
Backpropagation	-6,1243	112,09	154,96	~20ms	5*

LampiranB: Detail Output Training Backpropagation

Berikut adalah catatan lengkap output training Backpropagation manual (NumPy) selama 100 epoch dengan learning rate = 0,01:

Tabel B.1. Output Epoch Training Backpropagation

Epoch	Loss	Keterangan
0	2,928639	Nilai awal (post He-initialization)
20	0,342953	Penurunan 88,3% dari epoch 0
40	0,221105	Konvergensi mulai melambat
60	0,174948	Plateau region
80	0,144444	Penurunan gradual
100	[loss konvergen perlahan — tuning diperlukan]	Perlu epoch lebih banyak

Lampiran C: Ringkasan Performa Final Semua Model

Tabel C.1. Matriks Perbandingan Komprehensif Seluruh Model

Model	R ² Score	MAE (g/km)	RMS E (g/km)	Waktu Prediksi	Peringkat
Random Forest	0,9973	2,10	2,99	~50ms	1 ★
Decision Tree	0,9958	2,22	3,75	~5ms	2
Linear Regression	0,8810	13,46	20,03	~1ms	3
K-Means (k=8)	—	—	Inertia :	~10ms	Unsup.